ÉCOLE NATIONALE DE COMMERCE ET DE GESTION

ENCG SETTAT

Analyse de la performance logistique des pays

À partir du Logistics Performance Index (LPI) 2023

Projet de Data Science

Réalisé par : AHNNAOU Youness
AIT BOUSSALEM Israa

Encadré par : Abderrahim Larhlimi

Formation : Master 1 – Commerce International

Établissement : ENCG Settat

Année universitaire : 2026–2027

Année universitaire 2026–2027

Résumé

Ce projet porte sur l'analyse de la performance logistique des pays à partir des données du Logistics Performance Index (LPI) 2023 publiées par la Banque mondiale.

L'objectif est d'identifier des groupes de pays présentant des caractéristiques logistiques similaires en mobilisant des méthodes de clustering non supervisé.

L'étude repose sur six composantes du LPI : les douanes, les infrastructures, les expéditions internationales, la qualité des services logistiques, le suivi et la traçabilité, ainsi que la ponctualité.

Après les étapes de préparation des données, d'analyse exploratoire et de standardisation, plusieurs configurations de clustering ont été étudiées. Le modèle K-Means avec trois clusters a finalement été retenu pour son intérêt en matière d'interprétation économique.

Les résultats permettent de distinguer trois catégories de pays : à faible performance logistique, à performance intermédiaire et à performance élevée.

Mots-clés : Data Science, performance logistique, LPI 2023, clustering, K-Means, ACP, commerce international.

Table des matières

Résumé **i**

Introduction générale **1**

1 Cadre conceptuel : le Logistics Performance Index **1**
1.1 Présentation du LPI 1
1.2 Les six composantes étudiées 1

2 Présentation et préparation des données **2**
2.1 Source des données 2
2.2 Sélection des observations et des variables 2
2.3 Nettoyage et vérification 2
2.4 Standardisation 2

3 Analyse exploratoire des données **3**
3.1 Distribution des scores 3
3.2 Relations entre les composantes 4

4 Méthodologie de clustering **5**
4.1 Principe du clustering non supervisé 5
4.2 Algorithme K-Means 6
4.3 Clustering hiérarchique 6
4.4 Détermination du nombre de clusters 6

5 Évaluation et choix du modèle final **7**

6 Résultats et interprétation économique **7**
6.1 Présentation de la segmentation finale 7
6.2 Visualisation des groupes 8
6.3 Profils logistiques moyens 8
6.4 Interprétation économique 10
6.5 Analyse complémentaire des profils 10

7 Discussion et limites de l'étude **10**

Conclusion générale **11**

Table des figures

1 Distribution des scores des six composantes du LPI. 3
2 Dispersion des scores des six composantes du LPI à travers les pays (diagrammes en boîte). 3
3 Matrice de corrélation des six composantes. 4
4 Scores moyens des six composantes du LPI en 2023. 4
5 Les dix pays présentant les scores moyens les plus élevés sur les six composantes du LPI. 5
6 Les dix pays présentant les scores moyens les plus faibles sur les six composantes du LPI. 5
7 Répartition des pays selon les clusters K-Means, illustrée par les scores en douanes et en infrastructures. 6
8 Synthèse graphique des critères d'évaluation et de stabilité des configurations K-Means. 7
9 Variance expliquée et variance cumulée par les composantes principales. 8
10 Projection des pays selon les deux premières composantes principales. 8
11 Comparaison des scores moyens des composantes par catégorie. 9
12 Segmentation finale des pays avec K-Means à trois clusters projetée sur le plan factoriel de l'ACP. 9
13 Heatmap des profils logistiques standardisés par catégorie. 10

Introduction générale

Dans un contexte marqué par l'intensification des échanges internationaux, la performance logistique constitue un facteur important de compétitivité pour les économies nationales. La capacité d'un pays à assurer le transport, le suivi et la livraison des marchandises influence directement la fluidité des échanges commerciaux.

Les différences entre les systèmes logistiques nationaux peuvent être étudiées à travers le Logistics Performance Index (LPI), un indicateur publié par la Banque mondiale permettant d'évaluer plusieurs dimensions de la performance logistique.

Dans ce contexte, notre projet mobilise des méthodes de Data Science afin d'identifier des groupes de pays présentant des profils logistiques comparables.

Problématique

Comment les pays peuvent-ils être regroupés en fonction des six composantes de leur performance logistique, selon les données du Logistics Performance Index 2023 ?

Objectifs du projet

Les principaux objectifs sont :

— Comprendre les différentes dimensions de la performance logistique.

— Explorer et préparer les données du LPI 2023.

— Identifier des groupes de pays présentant des profils logistiques similaires.

— Évaluer les résultats de plusieurs méthodes de clustering.

— Interpréter les groupes obtenus dans une perspective économique et commerciale.

1 Cadre conceptuel : le Logistics Performance Index

1.1 Présentation du LPI

Le Logistics Performance Index est un indicateur développé par la Banque mondiale afin d'évaluer la performance des systèmes logistiques des pays.

Il permet notamment d'étudier les conditions dans lesquelles les marchandises circulent à travers les frontières et au sein des chaînes logistiques internationales.

1.2 Les six composantes étudiées

Notre analyse repose sur les six dimensions suivantes :

1. **Customs :** efficacité des procédures douanières.
2. **Infrastructure :** qualité des infrastructures de transport et de logistique.
3. **International Shipments :** facilité d'organisation des expéditions internationales.
4. **Logistics Competence and Quality :** qualité et compétence des services logistiques.
5. **Tracking and Tracing :** capacité de suivi et de traçabilité des expéditions.

6. **Timeliness :** respect des délais de livraison.

Les scores de ces composantes sont exprimés sur une échelle allant de 1 à 5.

2 Présentation et préparation des données

2.1 Source des données

Les données utilisées proviennent de la Banque mondiale et correspondent au Logistics Performance Index 2023.

Le fichier initial contient plusieurs observations et variables relatives aux pays, aux indicateurs et aux périodes étudiées.

L'analyse a été centrée sur les observations de l'année 2023 et sur les six composantes du LPI.

2.2 Sélection des observations et des variables

Après les opérations de filtrage et de transformation, un tableau structuré a été constitué avec une observation par pays et six variables quantitatives.

L'échantillon final comprend 139 pays.

Les identifiants des pays ont été conservés pour l'interprétation des résultats, mais n'ont pas été utilisés comme variables d'entrée du clustering.

2.3 Nettoyage et vérification

Plusieurs contrôles ont été effectués :

— Vérification des valeurs manquantes.

— Détection des éventuels doublons.

— Vérification de la cohérence des scores.

— Contrôle de l'échelle de mesure des variables.

Aucune valeur manquante n'a été détectée dans les six variables retenues pour la segmentation.

2.4 Standardisation

Les six variables possèdent la même échelle de mesure. Une standardisation a néanmoins été appliquée afin de centrer et réduire les variables avant le clustering.

La méthode StandardScaler transforme chaque variable selon :

$$Z = \frac{X - \mu}{\sigma}$$

où μ représente la moyenne et σ l'écart-type de la variable.

Cette transformation permet de rendre les variables comparables dans le calcul des distances.

3 Analyse exploratoire des données

L'analyse exploratoire vise à comprendre la distribution des scores logistiques et les relations entre les six composantes.

3.1 Distribution des scores

L'étude des distributions permet d'observer les différences de niveaux de performance entre les pays.

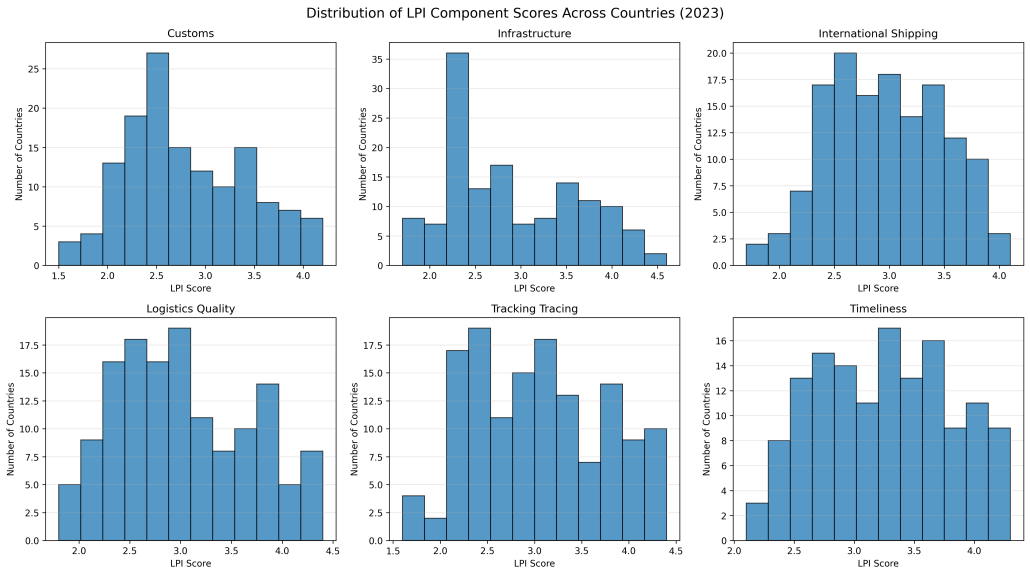


FIGURE 1 – Distribution des scores des six composantes du LPI.

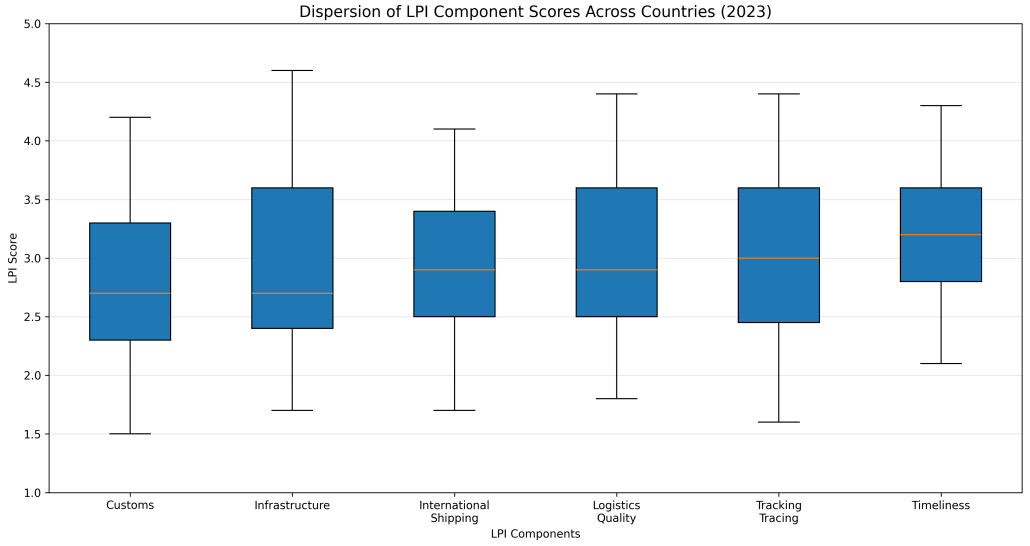


FIGURE 2 – Dispersion des scores des six composantes du LPI à travers les pays (diagrammes en boîte).

3.2 Relations entre les composantes

L'étude des corrélations permet d'identifier les relations entre les différentes dimensions de la performance logistique.

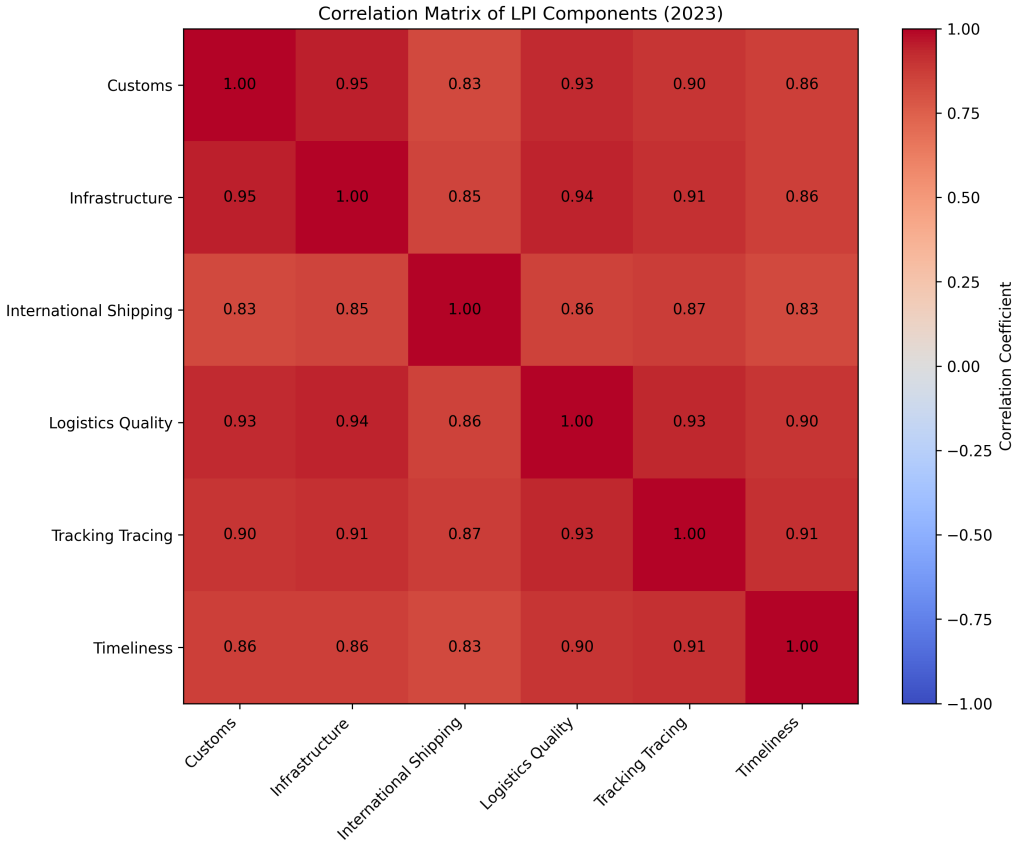


FIGURE 3 – Matrice de corrélation des six composantes.

Ces relations permettent de mieux comprendre les liens entre les infrastructures, les procédures douanières et la qualité des services logistiques.

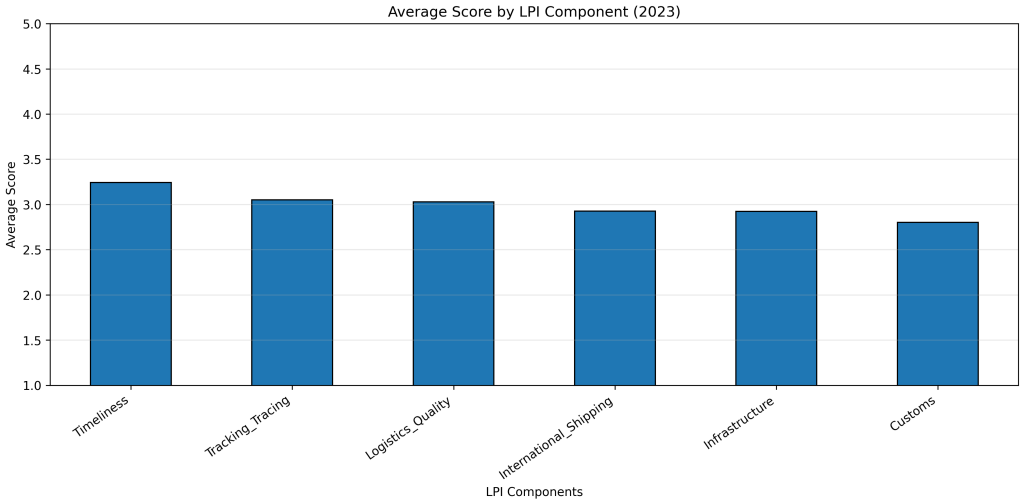


FIGURE 4 – Scores moyens des six composantes du LPI en 2023.

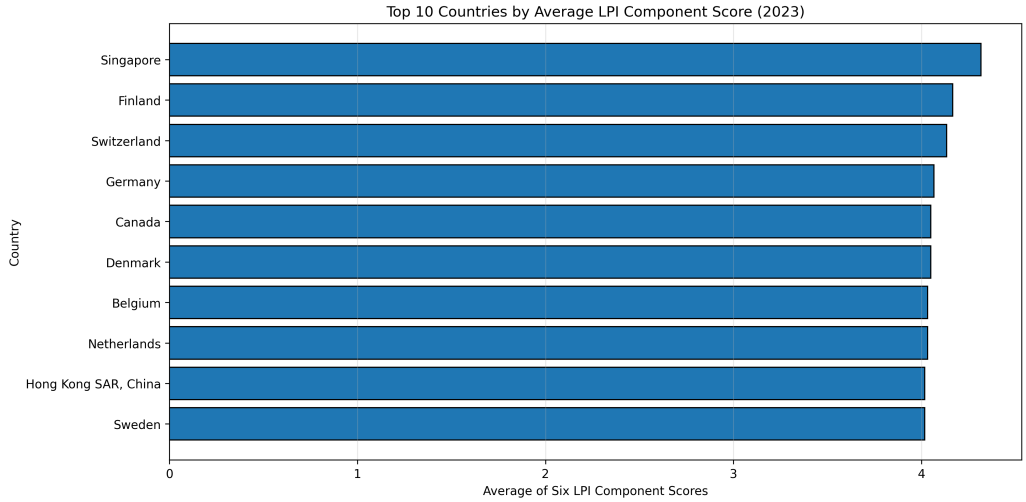


FIGURE 5 – Les dix pays présentant les scores moyens les plus élevés sur les six composantes du LPI.

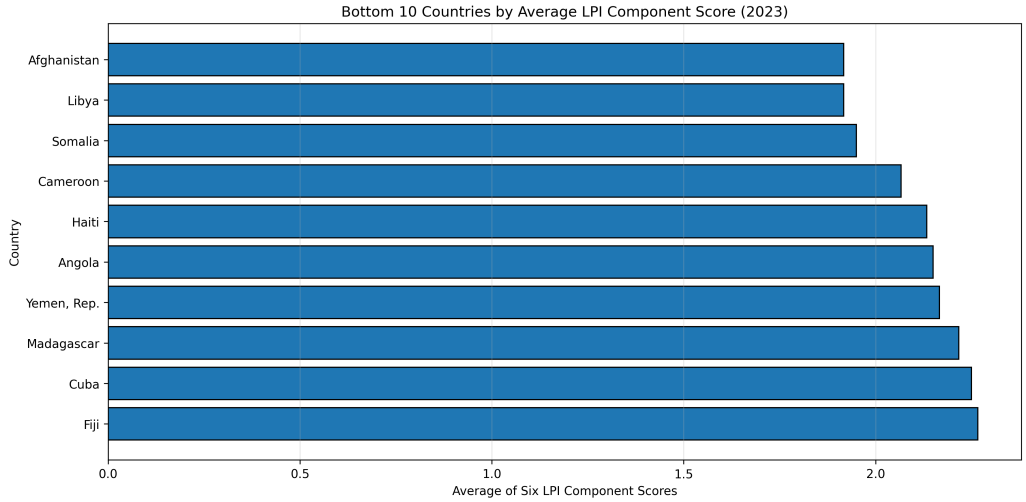


FIGURE 6 – Les dix pays présentant les scores moyens les plus faibles sur les six composantes du LPI.

4 Méthodologie de clustering

4.1 Principe du clustering non supervisé

Le clustering est une méthode d'apprentissage non supervisé qui consiste à regrouper les observations présentant des caractéristiques similaires.

Contrairement à l'apprentissage supervisé, cette approche ne nécessite pas de variable cible prédéfinie.

Dans notre étude, les pays sont regroupés à partir de leurs scores sur les six composantes du LPI.

4.2 Algorithme K-Means

K-Means est un algorithme de clustering qui cherche à répartir les observations en K groupes en minimisant la somme des distances au carré entre les observations et le centre de leur cluster.

L'objectif est de construire des groupes relativement homogènes à l'intérieur et distincts les uns des autres.

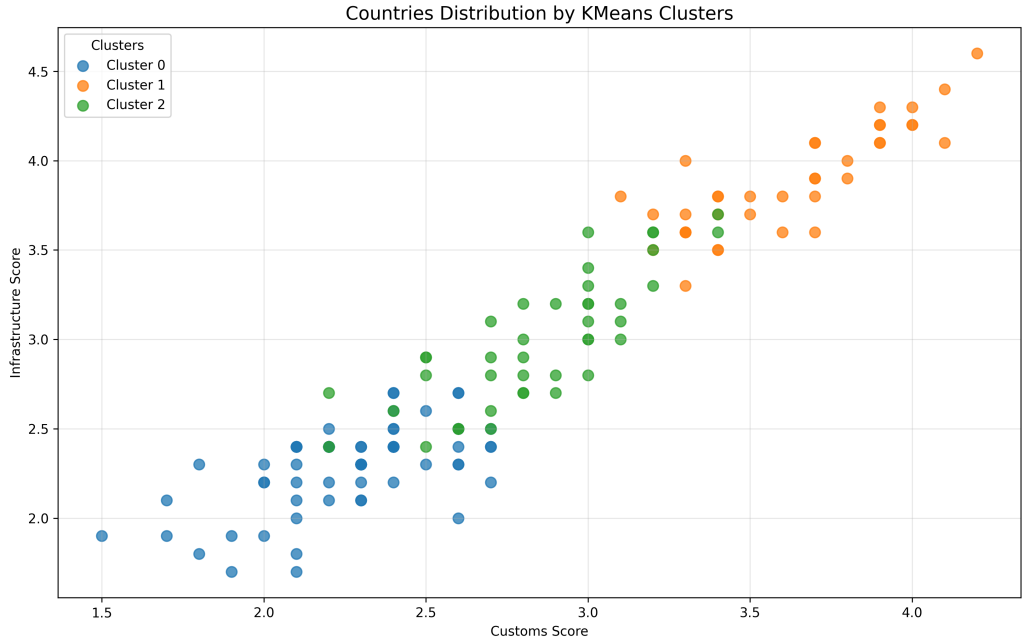


FIGURE 7 – Répartition des pays selon les clusters K-Means, illustrée par les scores en douanes et en infrastructures.

4.3 Clustering hiérarchique

Une méthode de clustering hiérarchique a également été étudiée afin de comparer les résultats obtenus avec ceux de K-Means.

Cette approche permet de construire progressivement des groupes en fonction de la proximité entre les observations.

4.4 Détermination du nombre de clusters

Plusieurs valeurs de K ont été étudiées afin d'identifier une segmentation pertinente.

Les méthodes d'évaluation mobilisées comprennent :

— La méthode du coude (Elbow Method).

— Le coefficient de silhouette.

— L'indice de Davies-Bouldin.

— L'indice de Calinski-Harabasz.

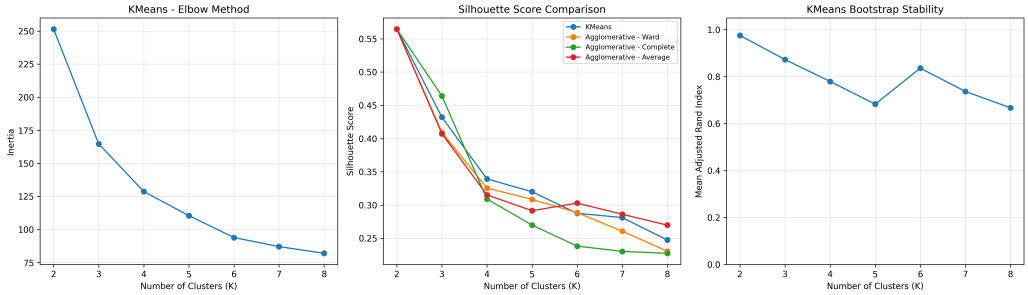


FIGURE 8 – Synthèse graphique des critères d'évaluation et de stabilité des configurations K-Means.

5 Évaluation et choix du modèle final

La comparaison des configurations étudiées montre que le modèle à deux clusters présente de meilleurs résultats selon les métriques statistiques examinées.

Pour $K = 2$, le coefficient de silhouette atteint 0,565, l'indice de Davies-Bouldin est de 0,604 et l'indice de Calinski-Harabasz est de 317,363.

Pour $K = 3$, le coefficient de silhouette est de 0,432, l'indice de Davies-Bouldin est de 0,780 et l'indice de Calinski-Harabasz est de 276,246.

Ainsi, la configuration à deux clusters présente une meilleure séparation statistique selon ces indicateurs.

Toutefois, notre objectif ne se limite pas à obtenir la meilleure séparation mathématique. Nous souhaitons également identifier des catégories de performance interprétables sur le plan économique.

C'est pourquoi nous retenons finalement K-Means avec trois clusters comme modèle principal d'interprétation.

Ce choix permet de distinguer trois niveaux de performance : faible, intermédiaire et élevée.

6 Résultats et interprétation économique

6.1 Présentation de la segmentation finale

Le modèle K-Means avec trois clusters a été retenu pour l'analyse économique.

La répartition obtenue est la suivante :

TABLE 1 – Répartition des pays selon les trois clusters

Catégorie	Nombre de pays	Pourcentage
Faible performance	61	43,88%
Performance intermédiaire	41	29,50%
Performance élevée	37	26,62%
Total	139	100%

6.2 Visualisation des groupes

L'Analyse en Composantes Principales (ACP) a été utilisée pour représenter les pays dans un espace de dimension réduite.

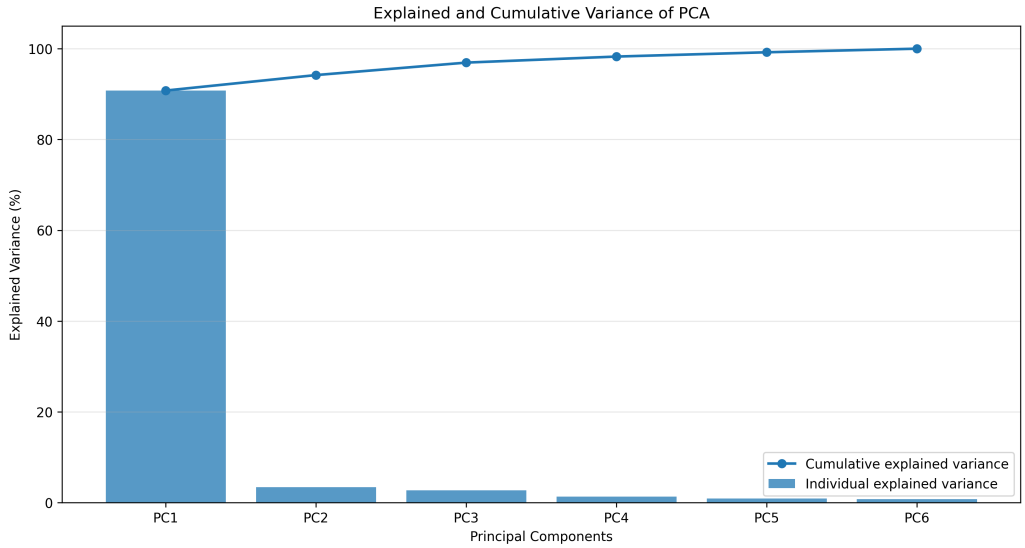


FIGURE 9 – Variance expliquée et variance cumulée par les composantes principales.

Elle facilite la visualisation des groupes obtenus tout en préservant une grande partie de l'information contenue dans les variables initiales.

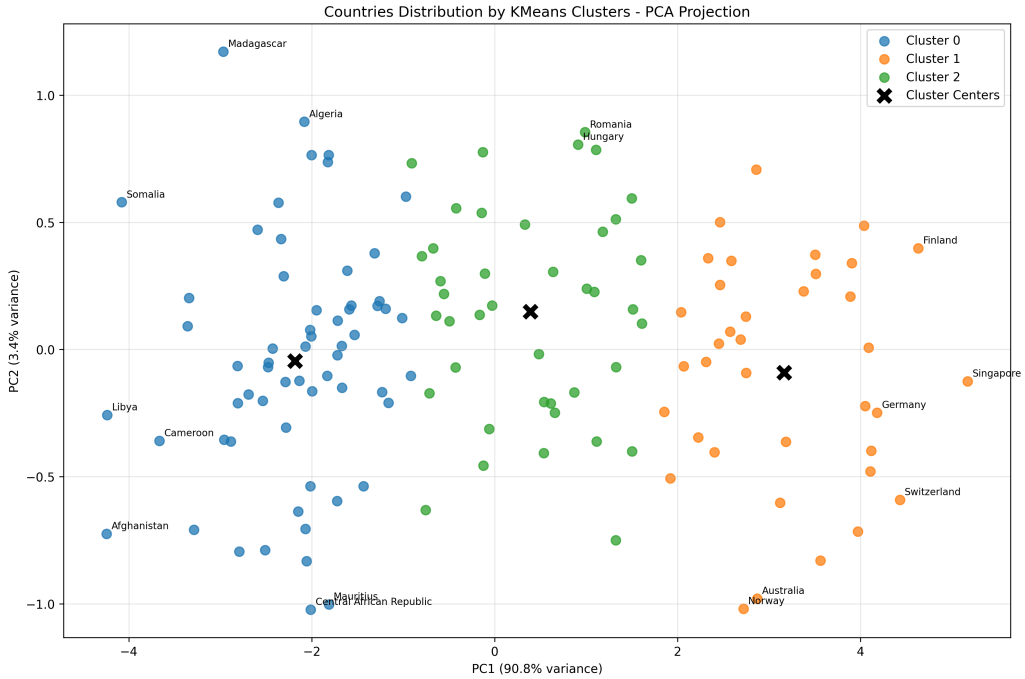


FIGURE 10 – Projection des pays selon les deux premières composantes principales.

6.3 Profils logistiques moyens

Le tableau suivant présente les scores moyens observés pour chaque catégorie.

TABLE 2 – Profils moyens des trois catégories

Catégorie	Douanes	Infra.	Expéd.	Qualité	Suivi	Délais
Faible	2,264	2,284	2,464	2,446	2,428	2,746
Intermédiaire	2,851	2,995	3,061	3,120	3,180	3,346
Élevée	3,627	3,892	3,535	3,889	3,935	3,946

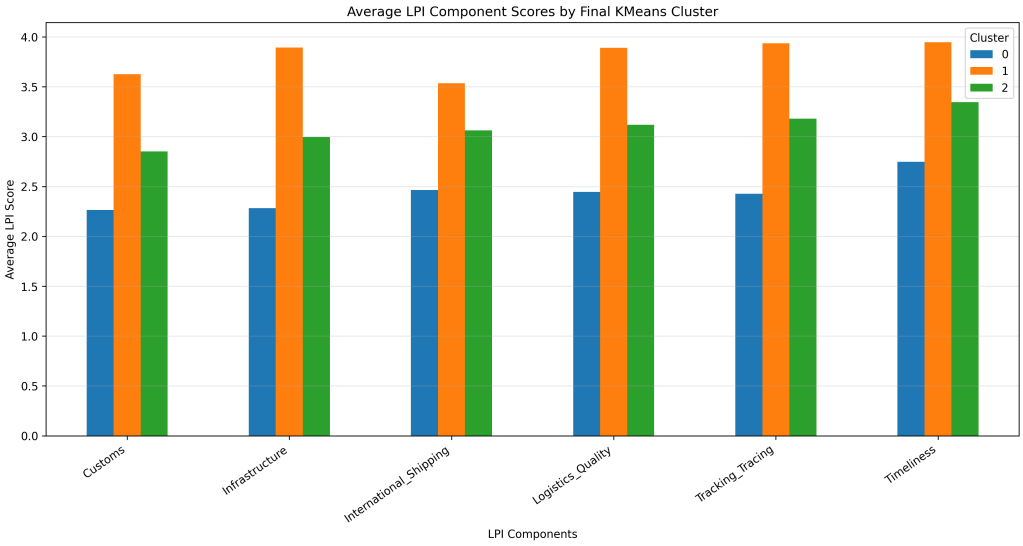


FIGURE 11 – Comparaison des scores moyens des composantes par catégorie.

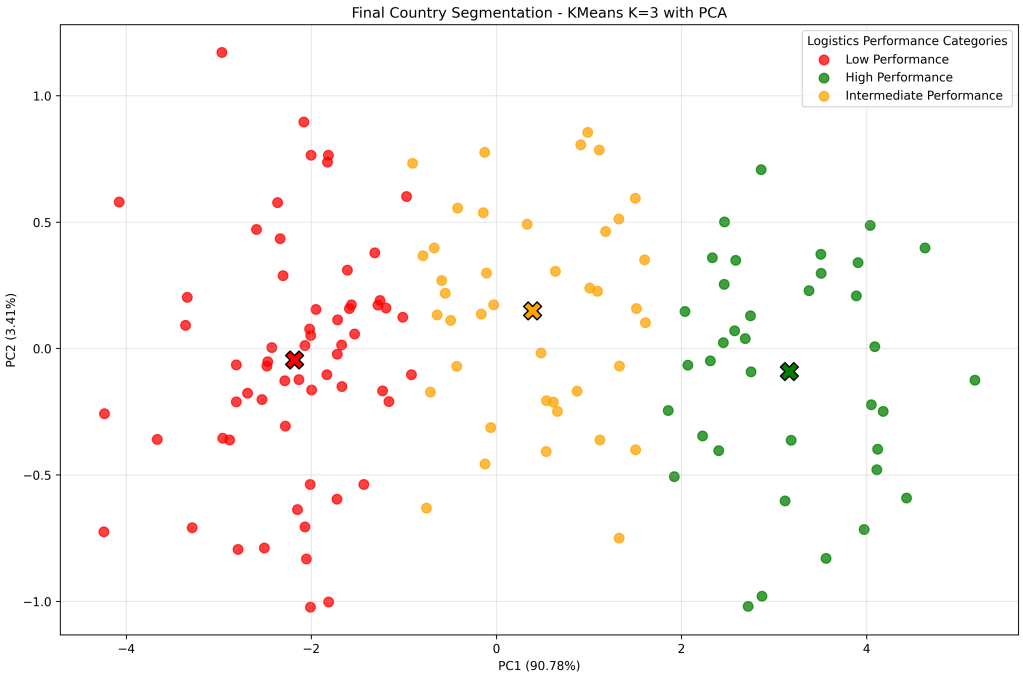


FIGURE 12 – Segmentation finale des pays avec K-Means à trois clusters projetée sur le plan factoriel de l'ACP.

6.4 Interprétation économique

Catégorie à faible performance :

Cette catégorie regroupe 61 pays. Les scores moyens sont relativement faibles sur les six dimensions, avec des niveaux particulièrement bas pour les douanes et les infrastructures.

Ces résultats mettent en évidence des difficultés potentielles liées à l'efficacité des procédures et à la qualité des équipements logistiques.

Catégorie à performance intermédiaire :

Cette catégorie comprend 41 pays. Elle présente des scores supérieurs à ceux du groupe à faible performance, mais reste en retrait par rapport au groupe le plus performant.

Elle correspond à des systèmes logistiques présentant un niveau de développement intermédiaire.

Catégorie à performance élevée :

Cette catégorie rassemble 37 pays. Elle se caractérise par des scores moyens élevés dans les six dimensions étudiées.

Les résultats traduisent une meilleure performance globale des systèmes logistiques de ces pays.

6.5 Analyse complémentaire des profils

La comparaison des profils permet d'identifier les dimensions sur lesquelles les écarts entre catégories sont les plus importants.

Cette analyse peut aider à orienter les réflexions sur les priorités d'amélioration des systèmes logistiques nationaux.



FIGURE 13 – Heatmap des profils logistiques standardisés par catégorie.

7 Discussion et limites de l'étude

Les résultats obtenus mettent en évidence l'existence de plusieurs profils logistiques parmi les pays étudiés.

La segmentation en trois catégories facilite la lecture économique des différences entre systèmes logistiques.

Néanmoins, certaines limites doivent être prises en compte.

Premièrement, le clustering dépend du choix des variables et de la méthode de standardisation.

Deuxièmement, les résultats dépendent du nombre de clusters retenu. La configuration à deux groupes présente de meilleurs indicateurs statistiques, tandis que celle à trois groupes offre une interprétation économique plus détaillée.

Troisièmement, les groupes obtenus décrivent des similarités statistiques et ne permettent pas, à eux seuls, d'établir des relations de causalité.

Enfin, l'étude repose sur les données de l'année 2023 et ne permet pas d'analyser directement l'évolution temporelle des performances logistiques.

Conclusion générale

Ce projet avait pour objectif de regrouper les pays selon les six composantes de leur performance logistique à partir des données du Logistics Performance Index 2023.

La démarche adoptée a combiné l'exploration des données, leur préparation, la standardisation, plusieurs méthodes de clustering et l'interprétation économique des résultats.

Le modèle K-Means à trois clusters a permis de distinguer trois catégories : faible performance, performance intermédiaire et performance élevée.

Bien que la configuration à deux clusters présente de meilleurs résultats statistiques, le choix de trois clusters a été privilégié pour sa capacité à fournir une segmentation plus détaillée et plus exploitable sur le plan économique.

Cette étude montre ainsi l'intérêt des méthodes de Data Science pour analyser les différences de performance logistique entre les pays et mieux comprendre les enjeux associés à la compétitivité du commerce international.

Des recherches futures pourraient intégrer plusieurs années de données ou d'autres indicateurs économiques afin d'approfondir cette analyse.

Références

[1] World Bank. *Logistics Performance Index (LPI)*. Banque mondiale. https://lpi.worldbank.org/

[2] Scikit-learn. *K-Means clustering*. Documentation officielle. https://scikit-learn.org/stable/modules/clustering.html

[3] Scikit-learn. *Principal Component Analysis (PCA)*. Documentation officielle. https://scikit-learn.org/stable/modules/decomposition.html

[4] Pandas. *Pandas Documentation*. https://pandas.pydata.org/docs/

[5] NumPy. *NumPy Documentation*. https://numpy.org/doc/